数据路径约定

- 原始数据集的名称对应关系如下
  - 单键.xlsx 对应 名称 为 single_set.xlsx
  - 轻轻.xlsx 对应 名称 为 double_small_set.xlsx
- 把上述excel放在data文件夹下面
- 由于lightgbm包要求类别从0开始，所以3个力的大小对应到的是[0,1,2],而16个位置对应到的是[0,1,2...15],**你不用改动，我是在读入数据的时候，把位置减1了**，你还是按原来那样从1开始记录位置就行

单键

single是单键，命令:

先预处理:

```
python preprocess.py --category single
```

效果是这样的:

```
(venv) (base) tsq@tsq-PC:~/PycharmProjects/OS/sensor_classify$ python preprocess.py --category single
总行数:147
总列数:21
第一行:['轻\\次数', 1.0, 2.0, 3.0, 4.0, 5.0, 6.0, 7.0, 8.0, 9.0, 10.0, 11.0, 12.0, 13.0, 14.0, 15.0, 16.0, 'time', '', '', '']
载入数据
载入数据
Done
```

再训练（现在只实现了决策树）:

```
python train.py  --category single
```

效果是这样的：

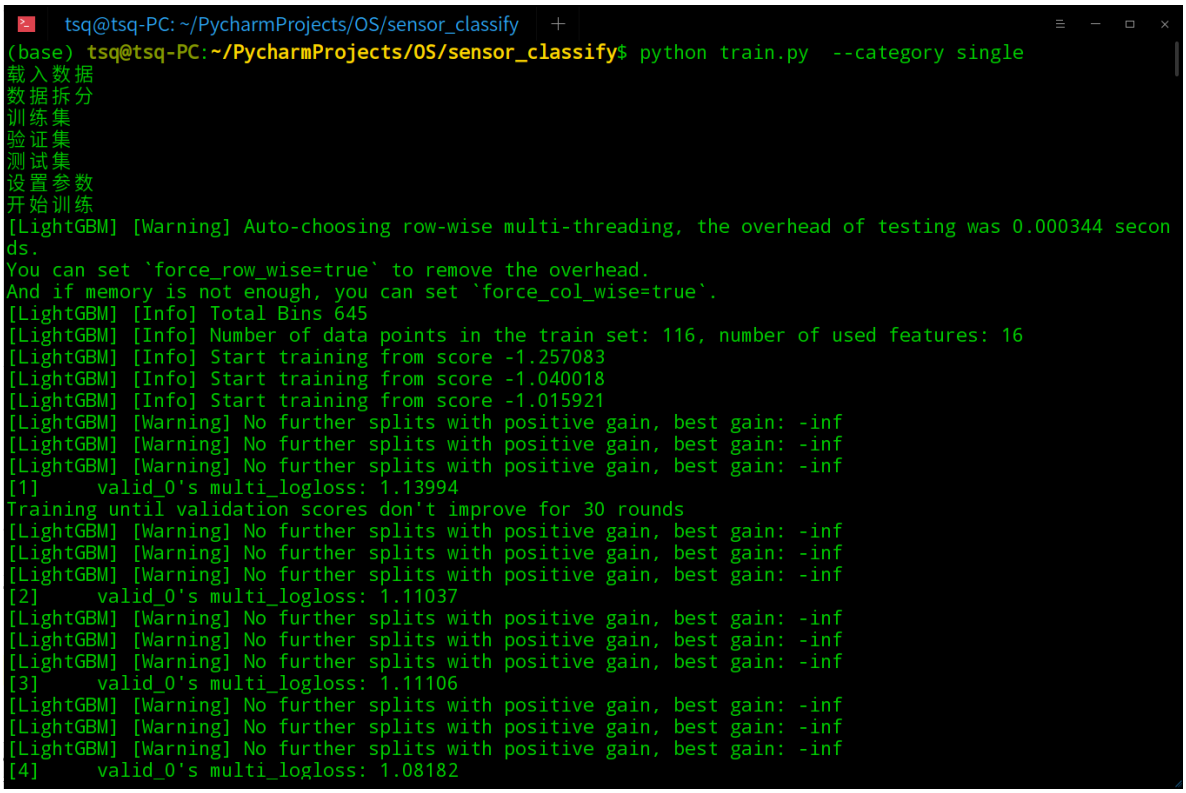

lgb决策树训练生成的东西

lgb的全称是lightgbm ，网上有很多它的资料，详细可以去搜一搜比如这个博客

会生成3个文件在./data/single/force/lgb下面

```
offline_test.csv
```

- 这个csv有3列： index,label,preds
  - index是验证集的一条数据在./data/single/force/raw.csv里的索引
  - label是数据的标签
  - preds是模型预测的分类结果

```
scores.txt
```

- scores.txt是调用sklearn的包测试出来的分数，采用多分类评价标准，如果最好理解的就是accuraccy,即分对了有百分之多少。详细可以去搜一搜比如这个博客
- 这次的lgb在single上的对力度的预测accuraccy达到了80%,而对位置的预测accuraccy则更高，为0.867

```
feature_score.csv
```

- 这个csv有2列：feature,importance
  - feature是特征的名称
  - importance是lgb决策树在训练过程中学习到的特征的重要程度，importance越高，这个特征就越会被决策树重视，用来做树分支的时候就越靠近树根

轻轻

double_small是轻轻，命令：

先预处理:

```
python preprocess.py --category double_small
```

效果是这样的:

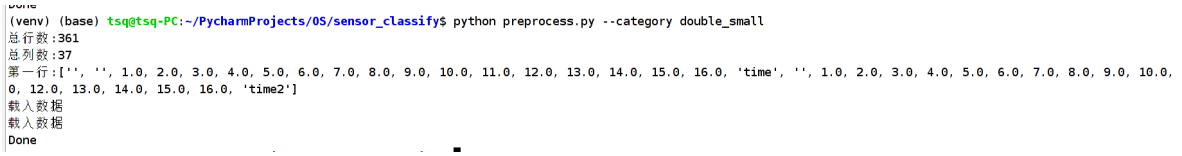

再训练:

```
python train.py  --category double_small
```

效果是这样的:

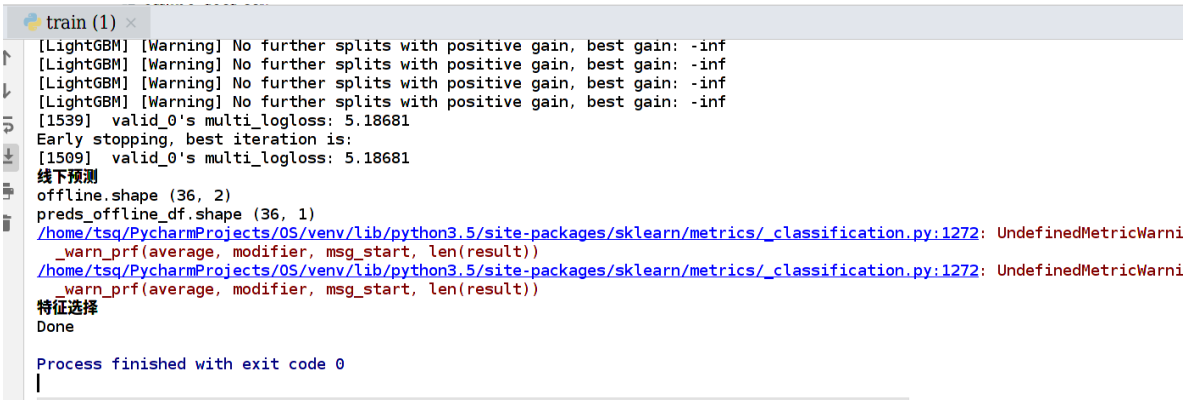

lgb决策树训练生成的东西

把2位置转换成了120类分类问题

- 会多生成1个文件在./data/single/force/lgb下面
    - 生成的offline_test_double_position.csv里面的pos_1_label和pos_2_label是excel里的标注的2个按下去的位置

发现，双位置训练需要一定的时间了，大约10秒

最后的准确率非常低，只有0.194

归一化

采用归一化之后，单键的准确率保持不变，轻轻的准确率提高到了0.25

现在默认使用归一化后的数据

如果要不用归一化，则命令为:

```
python train.py  --category double_small --not_normalize
```

SVM

加入了svm的分类器模型，调用的命令为：

单键：

```
python train.py  --category single --model svm
```

力准确率: 0.933

位置准确率: 0.533

因为double_small标注的force都是0，而svm训练的时候要求标签不只有一类，故，只能预测position：

```
python train.py  --category double_small --model svm --task position
```

哈哈，预测的准确率只有3%

2021年2月9日更新

按键顺序随机，按键的位置是在第A列，力度标注是在第R列

这样其实只要改动preprocess.py的creat_dataset函数就行

现在只对单键的做了更改：

- 加入了一个category叫做single_mixed，来表示是否用到的是mixed的乱序数据, single就还是代表上次那个每个点重复3次数据的single_set.xlsx
- 如果需要运行single_mixed数据集，只要如下2步：
  - 预处理：

    ```
    python preprocess.py --category single_mixed
    ```

  - 训练:

    ```
    python train.py  --category single_mixed --model lgb
    python train.py  --category single_mixed --model svm
    ```

把结果与之前的比较：

category	model	task	Accuracy	测试集数据量
single_mixed	lgb	force	0.727	44
single_mixed	lgb	position	0.818	44
single_mixed	svm	force	0.750	44
single_mixed	svm	position	0.614	44
single	lgb	force	0.800	15
single	lgb	position	0.867	15

category	model	task	Accuracy	测试集数据量
single	svm	position	0.533	15

2021年2月18日更新

增加了双键乱序的category(DONE)

增加了神经网络模型(DONE)

神经网络

纠结1： batch_size设置为多少?

ans: 先设置为1吧

纠结2：当双键按的时候，是否要把它归为120类分类问题？还是有更好的办法?

或许可以argmax的时候取2个prob的位置，算2个loss，然后加起来再backward

试了一些比较好的参数得到的结果：

单按键

```
python train.py  --category single_mixed --model network --lr 3e-3 --
weight_decay 1e-5 --task both
```

结果会在`data/single_mixed/force/network`和`data/single_mixed/position/network`下面，

- 里面的每个csv文件都是形如`model_epoch%d_val%.3f.csv`的
  - epoch后接着的整数是表示这是用第几个epoch验证得到的结果
  - val后面接着的分数是accuracy得分
- 里面会有个log.txt文件，就是训练的日志了，里面标出来了训练的参数、loss等
  - 其中, 比如`progress: 0.01  loss: 0.6960 (0.8719)`就是说在0.01个epoch的时候，从当前的样本往前数20个训练样本，这20个里面loss的中位数大小是0.6960。 而括号里的0.8719则是global_average，即累计所有训练样本的loss取的平均值
  - 具体可以看看utils.py是怎么写的

目前，我试了几个学习率的参数，你也可以调着试试，改动命令行里的`--lr`和`--weight_decay`就行，单键force的预测准确率最高为`0.795`，单键position的预测准确率最高为`0.977`

双按键

把双键处理为简单的120类分类任务：

```
python train.py  --category double_small --model network --lr 5e-4 --
weight_decay 3e-6  --task position --not_use_top2
```

结果会在`data/double_small/force/network/not_use_top2`下面，position的预测准确率最高为`0.528`

采用2个16维的prob位置向量(共32维)作为双键的预测位置的依据：

```
python train.py  --category double_small --model network --lr 3e-3 --
weight_decay 1e-5  --task position
```

结果会在`data/double_small/force/network/`下面，奇怪的是，position的预测准确率最高为`0.556`，并没有什么大提高

注意:

- 如果训练双键，运行的命令不含`--not_use_top2`的时候，会把整个`data/double_small/force/network/`目录删除，所以如果之前存在`data/double_small/force/network/not_use_top2`，也会被删除。
- 最好**先**训练不含`--not_use_top2`的模型，**后**训练含`--not_use_top2`的模型。或者你把文件复制保存在别的目录下也行

画图

命令，只要规定好log.txt文件的位置，就可以根据此log画出loss和accuracy随着训练的变化图

例如：

```
python utils.py --log_path
./data/double_small/position/network/not_use_top2/log.txt
```

就会使用`./data/double_small/position/network/not_use_top2/log.txt`来画图

图片会出现在`./figure/_data_double_small_position_network_not_use_top2_log`下面

目前，其他几个可以画出的神经网络训练变化图如下:

```
python utils.py --log_path ./data/double_small/position/network/log.txt
python utils.py --log_path ./data/single_mixed/position/network/log.txt
python utils.py --log_path ./data/single_mixed/force/network/log.txt
```

2021年2月21日更新

double_mixed分类

流程：

- 预处理:

```
python preprocess.py --category double_mixed
```

- 训练:

```
python train.py  --category double_mixed --model lgb
python train.py  --category double_mixed --model svm
```

神经网络预测position:

```
python train.py  --category double_mixed --model network --lr 3e-4 --
weight_decay 1e-6  --task position

python utils.py --log_path ./data/double_mixed/position/network/log.txt
```

神经网络预测force，由于只有3类，学习率太小容易过拟合:

```
python train.py  --category double_mixed --model network --lr 3e-3 --
weight_decay 1e-5  --task force

python utils.py --log_path ./data/double_mixed/force/network/log.txt
```

从double_mixed的结果看，Position准确率有一些提升空间，但是force的准确率已经很高了

v6.1更新:

svm和lgb也采用了同样的统计方式，获得的文件名是`val0.306_0right47_1right6_2right19.csv`

val后接的分数0.306是按$\frac{1right_{num}+2\times 2right_{num}}{2\times data_{num}}$计算的,其道理与v5.2时说的类似

而scores.txt里的accuracy就是$\frac{2right_{num}}{data_{num}}$

其中, $1right_{num}$指预测对一个键的数据数量，$2right_{num}$指预测对2个键的数据数量，$data_{num}$指数据总量

2021年2月27日更新

增加了新的默认 预测是8个键的包，名字叫:

sensor_classify_defualt8

用这个包，**运行的所有命令都与之前一样**，只不过默认的预测的键盘位置是1-8，采用的电信号也是1-8的

预处理完后，force下面的raw.csv长这样，只有8列特征:

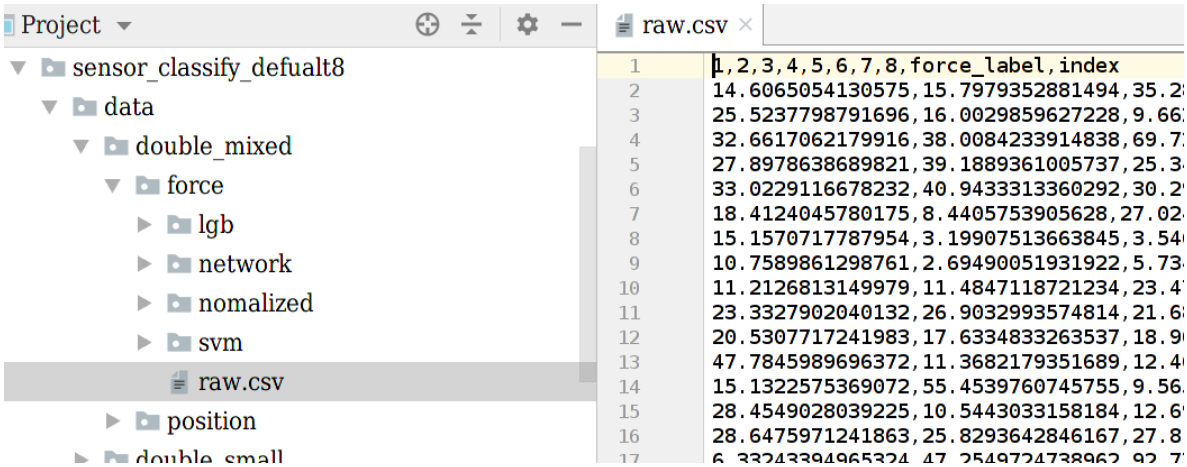
Project
sensor_classify_defualt8
data
double_mixed
force
lgb
network
nomalized
svm
raw.csv
position
raw.csv
1,2,3,4,5,6,7,8,force_label,index
14.6065054130575,15.7979352881494,35.2
25.5237798791696,16.0029859627228,9.66
32.6617062179916,38.0084233914838,69.7
27.8978638689821,39.1889361005737,25.3
33.0229116678232,40.9433313360292,30.2
18.4124045780175,8.4405753905628,27.02
15.1570717787954,3.19907513663845,3.54
10.7589861298761,2.69490051931922,5.73
11.2126813149979,11.4847118721234,23.4
23.3327902040132,26.9032993574814,21.6
20.5307717241983,17.6334833263537,18.9
47.7845989696372,11.3682179351689,12.4
15.1322575369072,55.4539760745755,9.56
28.4549028039225,10.5443033158184,12.6
28.6475971241863,25.8293642846167,27.8